Datorlab 3

1 Centrala gränsvärdessatsen

Den centrala gränsvärdessatsen (de stora talens lag) säger att summan $X = \sum_i^n X_i$ av n slumpvariabler X_i med olika fördelningar P_{X_i} är normalfördelad: $X \sim N(\mu, \sigma)$ för något μ och σ, då antalet $n \to \infty$. (Ett villkor är att det finns en övre gräns för fördelningarnas varianser.)

Slumpvariabler kan användas för att beskriva mätfel. När du gör en mätning (ett experiment) kommer du aldrig att lyckas mäta exakt. Du kanske inte lyckades placera linjalens nollmarkering rätt, du kanske skattade fel när du uppskattade ett värde mellan två skalstreck, om linjalen är av trä kan längden variera med luftfuktigheten. Eller kanske det du mätt på har ändrat längd sedan du mätte, så att ditt värde på längden nu är lite fel.

Ett sådant mätfel kan ses som en slumpvariabel X_i med en (ofta okänd) sannolikhetsfördelning P_{X_i}. Vi får det totala mätfelet genom att addera de individuella mätfelen: $X = \sum_i X_i$. Vad har summan för sannolikhetsfördelning? Vad händer om du adderar två, tre eller tio slumpvariabler? Det ska vi nu undersöka för några olika fall genom att (elementvis) summera stickprov från ett antal slumpvariabler.

2 Instruktion

Svar printas tillsammans med uppgiftsnumret. När olika alternativ ska testas så kan ni kommentera ut andra alternativ, exempelvis:

```
print( "Svaret på uppgift 1 är ... "          ).
...
#r = sps.uniform.rvs(size=(N,n),loc=0,scale=1)
r = sps.norm.rvs(size=(N,n),loc=0,scale=1)
...
```

2.1 Uppgifter

1. Varför är normalfördelade slumpvariabler ofta en rimlig modell av mätfel?
2. Generera stickprov av storlek $N = 10^5$ från $n = 2$ stycken likformigt (uniformt) fördelade slumpvariabler. Du kan göra en lista med längd n där varje element är en array av N slumptal, eller en $n \times N$-matris av slumptal (se exemplet i slutet).
3. Summera (elementvis) dina n arrayer (eller n rader i matrisen). Resultatet är en array med N element, där varje element är en summa av n termer. Du kan använda `np.sum()` med `axis=` (se exemplet i slutet).

4. Gör ett histogram med `density=True` av ditt resultat. Beräkna medelvärde (`np.mean()`) och standardavvikelse (`np.std()`) för resultatet och plotta en normalfördelad täthetsfunktion med dessa parametrar över histogrammet (se exempel i slutet).
5. Testa att ändra antalet variabler som summeras, $n = 1, 2, 3, 5, 20, \ldots$ Hur stort behöver n vara för att resultatet ska se normalfördelat ut?
6. Funkar centrala gränsvärdessatsen för andra fördelningar? Testa att ta stickproven från dessa fördelningar:
   - Likformig (uniform)
   - Normal
   - Laplace
   - Exponential
   - Cauchy (funkar inte!)

2.2 Extra frågor

Behöver inte redovisas, men testa gärna.

1. Vad händer om du summerar variabler från **olika** fördelningar? I exemplet nedan görs det enkelt såhär:

```
r  = sps.uniform.rvs(size=(n,N),...)
r += sps.laplace.rvs(size=(n,N),...)`
r += ...
```

1. Hur ser resultatet ut om stickproven multipliceras istället? Byt ut `np.sum()` mot `np.product()` (fortfarande med `axis=`), och ta bort normalfördelningskurvan. (Detta kallas för "product distribution".)

---

3 Exempel

[1]:
```
import matplotlib.pyplot as plt
import scipy.stats as sps
import numpy as np

# Parametrar
edge  = 1
width = 3
N     = 10**5
n     = 2 # = 1,2,3,5,20,100,500

# Generera 'N' stickprov från 'n' slumpvariabler (i N*n-matris)
r   = sps.uniform.rvs(size=(n,N), loc=edge, scale=width)

# Summan 's' av stickproven (raderna) ska bli normalfördelad då 'n' blir stor
s   = np.sum(r,axis=0)
```

```python
# Stämmer detta? Vi testar:

# Plotta histogram av 's' (normaliserat med density=True)
plt.hist(s, bins=100, density=True)

# mu & sigma för 's'
mu  = np.mean(s)
sig = np.std(s)
print(f"Summerade variabelns parametrar: mu={mu:.4f} sigma={sig:.4f}")

# Plotta normalfördelning med mu & sigma från 's'
x_pdf = np.linspace(mu-4*sig, mu+4*sig, 100)
y_pdf = sps.norm.pdf(x_pdf, loc=mu, scale=sig)
plt.plot(x_pdf, y_pdf)

plt.show()
```

```
Summerade variabelns parametrar: mu=4.9985 sigma=1.2229
```

